Estadística para la lingüística de corpus

De la hipótesis nula al mapa léxico

Adrián Cabedo Nebot

2026-05-05

Universitat de València · Catedrático de Lengua Española

Bienvenida y presentación

Adrián Cabedo Nebot
Catedrático de Lengua Española · Universitat de València
adrian.cabedo@uv.es

Materiales del curso
https://github.com/acabedo/navarra2026

Seminario · Universidad de Navarra · 5 mayo 2026

Estructura

I · Fundamentos estadísticos

II · Estadística de corpus

III · Colocaciones

IV · R en la práctica

V · Caso integrado

Duración: 1 h 30 min

¿De qué vamos a hablar hoy?

Punto de partida

Los gestores de corpus (Sketch Engine, AntConc…) calculan automáticamente medidas estadísticas.
¿Sabemos **qué hacen exactamente**, por qué los resultados difieren y cómo replicarlos?

Objetivo

- Log-likelihood · Log-ratio · Simple Maths
- Keyness · Colocaciones
- Replicarlo en **R**

Corpus de ejemplo

Discursos de investidura

Rajoy 2011, 2016a, 2016b

Sánchez 2020, 2023

Fuente: Congreso de los Diputados

Pregunta guía

¿Qué léxico define *ideológicamente* a Sánchez frente a Rajoy?

Parte I: Fundamentos estadísticos

¿Por qué estadística en lingüística?

El problema central

Observamos patrones en los datos lingüísticos. ¿Ese patrón es **real** o **fruto del azar**?

Ejemplos:

- ¿Usa Sánchez más sustantivos que Rajoy?
- ¿Es *cambio* una palabra clave de la izquierda?
- ¿Aparece *libertad* más en Rajoy?
- ¿Son más largas las oraciones de Sánchez? $\longrightarrow$

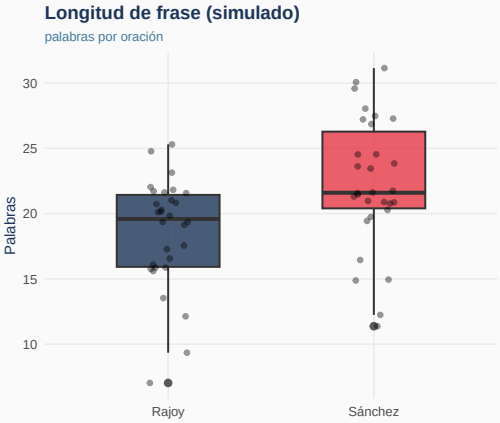

La estadística nos ayuda a **separar la señal del ruido**.

Conceptos clave: población y muestra

Población
Conjunto **completo** de todos los elementos de interés.

Todos los discursos políticos en España (1978–hoy)

Muestra
Subconjunto **observable** para inferir propiedades de la población.

Los 5 discursos de investidura de Rajoy y Sánchez

Clave: generalizar de la muestra a la población requiere que sea **representativa**.

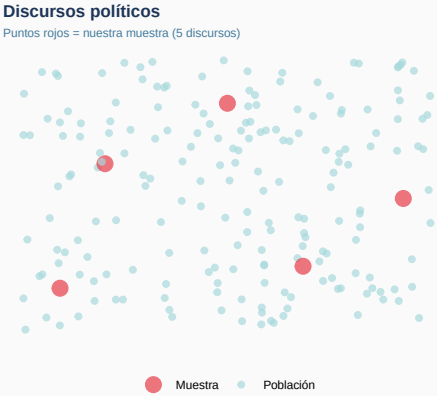

Nuestro corpus: los discursos de investidura

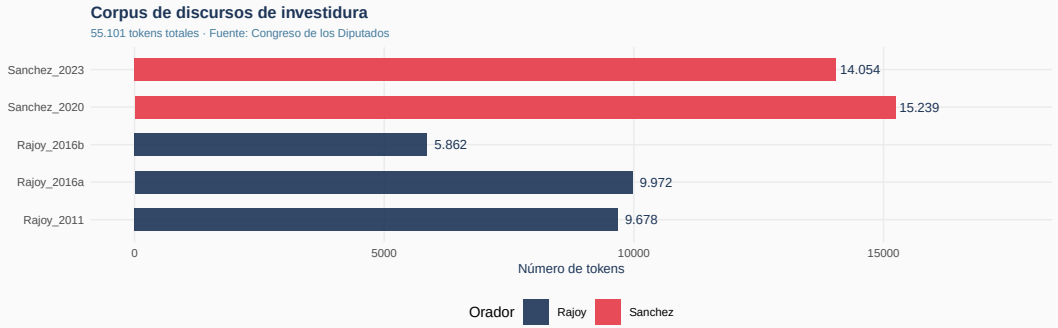

Textos disponibles en https://github.com/acabedo/navarra2026

Riqueza léxica: tipos y tokens

Token
Cada **ocurrencia individual** de una palabra en el texto, incluyendo repeticiones.

«España, España, nuestra España» → 4 tokens

Type (tipo)
Cada **forma léxica única**, independientemente de cuántas veces aparezca.

«España, España, nuestra España» → 2 types

TTR = Tipos / Tokens: sensible al tamaño del texto.

Root TTR = Tipos / $\sqrt{\text{Tokens}}$: más estable para comparar textos de distinta longitud.

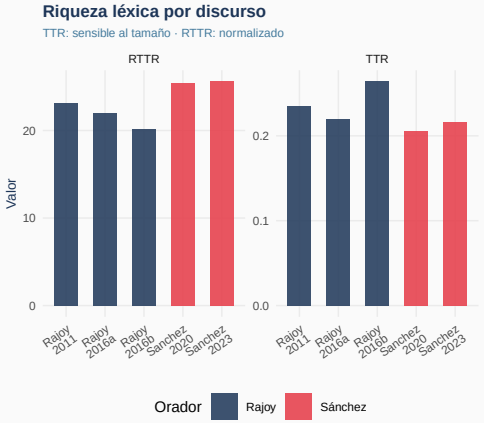

Tipología de variables

Variables cuantitativas

Continuas
Valores en un rango continuo: longitud de oración, F0, duración

Discretas
Valores enteros contables: frecuencia léxica, n.º de cláusulas

Variables categóricas

- **Nominales**: orador, partido, género léxico
- **Ordinales**: registro (formal > neutro > coloquial)

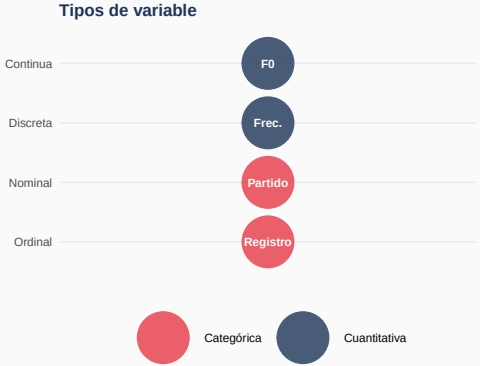

La lógica de la hipótesis

H_0: hipótesis nula

Afirma que **no hay diferencia**. Es la que la estadística intenta refutar.

*"Sánchez y Rajoy usan **España** con igual frecuencia"*

H_1: hipótesis alternativa

Afirma que **sí hay diferencia**. Es lo que el investigador quiere mostrar.

*"Sánchez usa **España** con distinta frecuencia que Rajoy"*

Idea clave: en un mundo posible donde Rajoy y Sánchez usaran *España* con la misma frecuencia, ¿qué probabilidad habría de obtener una diferencia tan grande como la observada? Eso es lo que mide el valor p.

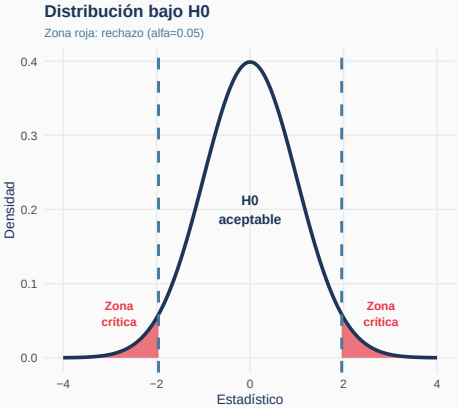

Errores tipo I y tipo II

Cuando decidimos si rechazar H_0, podemos equivocarnos de dos formas:

Error tipo I (falso positivo)
Rechazamos H_0 cuando en realidad era cierta.

Concluimos que Sánchez usa más «España», pero la diferencia era puro azar.

Probabilidad $= \alpha$ (umbral de significación, p.ej. 0.05)

Error tipo II (falso negativo)
No rechazamos H_0 cuando en realidad era falsa.

No detectamos una diferencia real porque nuestra muestra era demasiado pequeña.

Probabilidad $= \beta$ · Potencia $= 1 - \beta$

Matriz de decisión

El valor *p*: qué es (y qué NO es)

Definición

Probabilidad de obtener resultados **tan extremos o más** asumiendo H_0 cierta.

Si Rajoy y Sánchez usaran «España» con igual frecuencia, ¿con qué probabilidad veríamos una diferencia tan grande como la observada?

Umbrales convencionales

$p < 0.05$	Significativo (*)
$p < 0.01$	Muy significativo (**)
$p < 0.001$	Altamente sign. (***)

El p-valor NO es:

- La probabilidad de que H_0 sea verdadera
- Una medida del tamaño del efecto
- Garantía de relevancia lingüística
- Un umbral natural: el 0.05 es **una convención estadística**

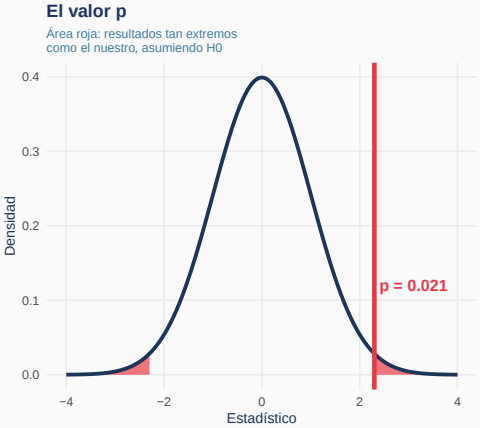

Tamaño del efecto: la significación no lo es todo

Prueba t de Student (simulado)

Compara las medias de dos grupos. Los datos son **simulados** para ilustrar el concepto; las palabras y frecuencias concretas no corresponden al corpus real.

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

En R: `t.test(grupo_sanchez, grupo_rajoy)`

Los dos paneles (datos exactos del gráfico)

Izquierda ($n = 30$): $\bar{x}_S \approx 10.4$, $\bar{x}_R \approx 11.2 \rightarrow$ diferencia 0.8 palabras, p calculado en tiempo real $\rightarrow$ **no significativo**.

Derecha ($n = 3000$): $\bar{x}_S \approx 10.0$, $\bar{x}_R \approx 10.1 \rightarrow$ diferencia 0.1 palabras, p calculado en tiempo real $\rightarrow$ **significativo**. Con n enorme, diferencias mínimas resultan significativas.

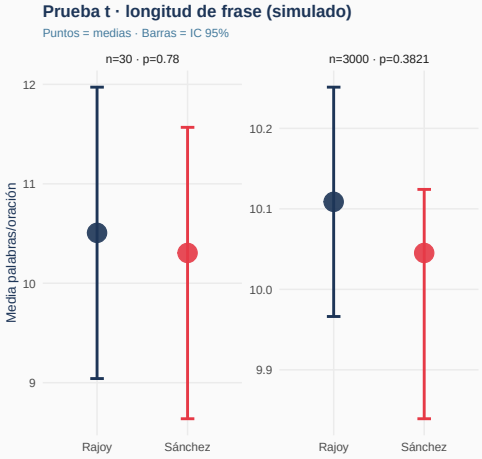

Tamaño del efecto vs. tamaño de la muestra

El problema del n grande

Con muestras muy grandes, casi **cualquier diferencia resulta significativa** estadísticamente, aunque sea irrelevante en la práctica.

Ejemplo

Un corpus de 10 millones de tokens puede detectar como significativa una diferencia de **0.001 palabras por oración**. Eso no tiene ninguna relevancia lingüística.

Solución: reportar siempre el tamaño del efecto

El tamaño del efecto mide la **magnitud real** de la diferencia, independientemente del n:

- **Cohen's** d $\rightarrow$ para comparaciones de medias (prueba t)
- **Log-ratio** $\rightarrow$ para frecuencias léxicas en corpus
- **Cramér's** V $\rightarrow$ para tablas de contingencia (χ^2)

Regla práctica

$\lvert d \rvert < 0.2$	Efecto pequeño
$\lvert d \rvert \approx 0.5$	Efecto medio
$\lvert d \rvert > 0.8$	Efecto grande

En corpus léxicos, un **log-ratio** > 1 indica que una palabra es **más del doble** de frecuente en un corpus que en el otro $\rightarrow$ efecto claro.

En R

```
effectsize::cohens_d(g1, g2)

textstat_keyness(..., measure="lr")
```

Lo que siempre hay que comunicar

Elemento	Herramienta en corpus
Estadístico	LL, χ^2, t
p-valor	Tablas de χ^2
Tamaño efecto	Log-ratio, Cohen's d
Dispersión	DP, % textos

Significación estadística $\neq$ Relevancia lingüística

Ejemplo de redacción en un artículo

*"La palabra **cambio** aparece significativamente más en los discursos de Sánchez que en los de Rajoy* (LL = 15.27, p $<$ 0.0001)*, con un tamaño del efecto moderado* (log-ratio = 1.68)*, lo que indica que es aproximadamente el doble de frecuente en el corpus de Sánchez. La palabra está presente en todos los discursos del corpus foco (dispersión = 100 %)."*

Parte II: Estadística de corpus

¿Qué vamos a ver en esta parte?

En las siguientes diapositivas se explican y ejemplifican con nuestro corpus real (Rajoy vs. Sánchez) los siguientes estadísticos y medidas:

Medidas de frecuencia
1. Frecuencia normalizada (ptw / pmw)

→ Comparar textos de distinto tamaño

Significación estadística
2. Log-likelihood (LL) · χ^2

→ ¿Es real la diferencia de frecuencia?

Tamaño del efecto
3. Log-ratio (LR) — Hardie (2014)

4. Simple Maths — Sketch Engine

5. %DIFF · Relative Risk · Odds Ratio · BIC

→ ¿Cuánto importa la diferencia?

Palabras clave
6. Keyness = LL + LR + Dispersión

→ ¿Qué léxico define a cada orador?

Dispersión
7. Deviation of Proportions (DP)

→ ¿Está distribuida la palabra en todo el corpus?

Colocaciones
8. MI · t-score · logDice

→ ¿Qué palabras van juntas con más frecuencia de la esperada?

N-gramas
9. Bigramas y trigramas

Comparativa Sketch Engine vs R

Sketch Engine

+ Interfaz amigable, resultados rápidos
+ Corpus de referencia ya cargados
– **Datos en servidores externos** (privacidad)
– Caja negra: no siempre sabes el cálculo exacto
– Acceso de pago, reproducibilidad limitada
– Difícil escalar a corpus propios muy grandes

R (tidyverse / quanteda)

+ **Tus datos no salen de tu ordenador**
+ Código reproducible y auditable
+ Libre y gratuito, comunidad enorme
+ Escalable · Visualización de calidad

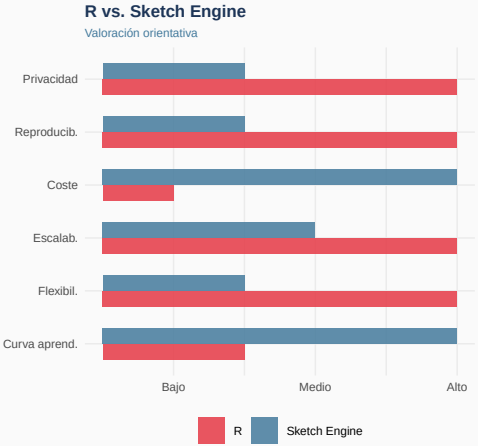

Introducción a R y RStudio

R — lenguaje estadístico, libre y gratuito
https://www.r-project.org

RStudio — entorno integrado (IDE) para R
https://posit.co/download/rstudio-desktop

Paquetes esenciales para corpus

- `tidyverse`: manipulación y visualización
- `quanteda`: análisis de corpus
- `ggplot2`: gráficos de calidad
- `ggrepel`: etiquetas sin solapamiento

Instalación (3 pasos)

1. Instalar R desde CRAN
2. Instalar RStudio
3. En la consola de R:

```
install.packages(c(
  "tidyverse", "quanteda",
  "quanteda.textstats", "ggrepel"
))
```

Materiales
https://github.com/acabedo/navarra2026

Frecuencia normalizada: comparar lo incomparable

El problema

Textos de distinta longitud: no comparar frecuencias brutas.

Frecuencia normalizada

Ocurrencias si el texto tuviera exactamente N tokens.

$$f_{\text{norm}} = \frac{f_{\text{bruta}}}{N_{\text{tokens}}} \times 1000$$

Ejemplo: *españa* (datos reales)

- Sánchez: 120 / 14266 tokens → **8.41 ptw**
- Rajoy: 161 / 12366 tokens → **13.02 ptw**

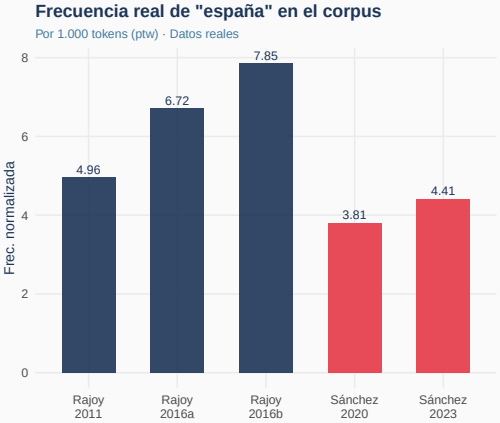

Código R: frecuencia normalizada

```r
library(tidyverse); library(quanteda)

# Leer corpus directamente desde los archivos .txt
rutas <- c(Rajoy_2011="2011_Rajoy.txt", Rajoy_2016a="2016_Rajoy.txt",
           Rajoy_2016b="2016b_Rajoy.txt",
           Sanchez_2020="2020_Sa_nchez.txt", Sanchez_2023="2023_Sa_nchez.txt")
textos   <- map_chr(rutas, ~paste(readLines(.x,encoding="UTF-8"),collapse=" "))
corp     <- corpus(textos)
docvars(corp,"orador") <- c("Rajoy","Rajoy","Rajoy","Sanchez","Sanchez")
toks     <- tokens(corp, remove_punct=TRUE) |>
  tokens_tolower() |> tokens_remove(stopwords("es"))
dfm_corp <- dfm(toks)

# Frecuencia normalizada de "españa" por 1.000 tokens
dfm_norm <- dfm_weight(dfm_corp, scheme="prop") * 1000
# → las frecuencias salen DIRECTAMENTE de los textos, no se hardcodean
as.numeric(dfm_norm[, "españa"])
```

Nota quanteda: `dfm_weight(scheme="prop")` normaliza automáticamente por longitud de documento. No es necesario calcular $f/N \times 1000$ manualmente.

¿Pero es esa diferencia **estadísticamente significativa**?

Nube de palabras: los cinco discursos

Top 25 palabras por discurso · Sin stopwords

Tamaño proporcional a la frecuencia normalizada (ptw)

Log-likelihood: ¿es real la diferencia?

Log-likelihood (LL)

Prueba estadística: ¿es la diferencia de frecuencia entre dos corpus mayor de lo esperable por azar?

$$LL = 2 \sum O_i \ln\left(\frac{O_i}{E_i}\right)$$

O_i = frec. observada · E_i = frec. esperada · $\ln$ = logaritmo natural (base $e \approx 2.718$)

Umbrales de significación (χ^2, 1 g.l.)

LL $\geq$ 3.84	$p < 0.05$	*
LL $\geq$ 6.63	$p < 0.01$	**
LL $\geq$ 10.83	$p < 0.001$	***
LL $\geq$ 15.13	$p < 0.0001$	****

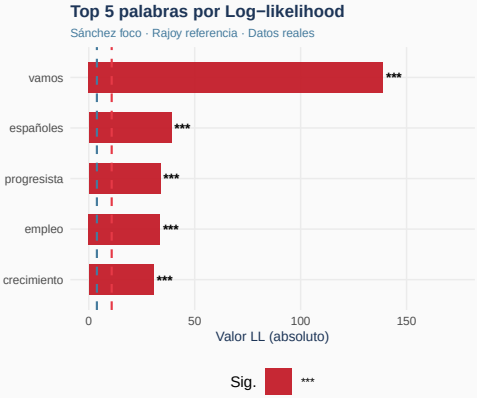

¿Por qué Sketch Engine usa LL 15.13?

Sketch Engine aplica un umbral más estricto que el estándar académico de $p < 0.05$ (LL $= 3.84$).

La razón: comparaciones múltiples
Cuando analizamos un corpus buscamos palabras clave entre **miles de tipos léxicos** a la vez. Con $p < 0.05$, el 5 % de palabras resultarían significativas **por puro azar**.

Al exigir $p < 0.0001$ (LL ≥ 15.13), reducimos drásticamente esos falsos positivos.

En la práctica (vocabulario de 10.000 palabras)
- Con $p < 0.05 \rightarrow$ ~**500 falsas alarmas** esperadas - Con $p < 0.0001 \rightarrow$ ~**1 falsa alarma** esperada

Fuoli & Beelitz (2024) adoptan también LL ≥ 15.13.

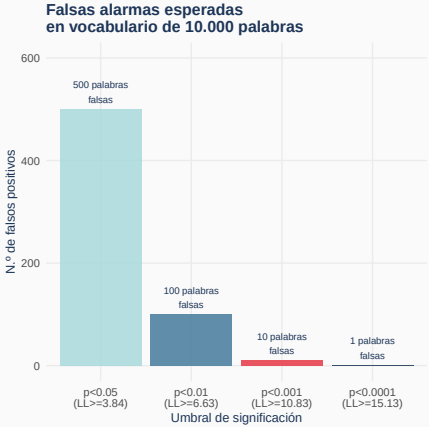

Código R: Log-likelihood

```r
# OPCIÓN A: calcular manualmente (didáctica)
calc_LL <- function(O1, O2, N1, N2) {
  total <- O1 + O2
  E1 <- total * N1 / (N1 + N2)
  E2 <- total * N2 / (N1 + N2)
  # log() en R = logaritmo natural (ln)
  LL <- 2*(ifelse(O1>0, O1*log(O1/E1),0) +
           ifelse(O2>0, O2*log(O2/E2),0))
  round(LL, 2)
}

# OPCIÓN B (recomendada): usar quanteda directamente
# Las frecuencias salen del corpus, NO se hardcodean
library(quanteda.textstats)
kw <- textstat_keyness(dfm_corp,
        target  = docvars(dfm_corp,"orador")=="Sanchez",
        measure = "lr")   # devuelve LL (chi2) y LR en una tabla

# Ver las 20 palabras más características de Sánchez
head(kw, 20)
# La columna "chi2" contiene el LL; "lr" el log-ratio
```

quanteda: `textstat_keyness()` calcula LL y LR directamente desde la DFM. No hace falta extraer frecuencias manualmente ni hardcodear ningún valor.

Log-ratio: cuántas veces más frecuente

Log-ratio (LR)

Medida del **tamaño del efecto**: cuántas veces más frecuente es una palabra en el corpus foco respecto a la referencia.

$$LR = \log_2 \left(\frac{f_{\text{foco}}/N_{\text{foco}}}{f_{\text{ref}}/N_{\text{ref}}} \right)$$

- $LR = 0$: misma frecuencia $\rightarrow$ **barra gris (Neutro)**
- $LR = 1$: **el doble** en Sánchez
- $LR = 2$: **cuatro veces** más en Sánchez
- $LR = -1$: **la mitad** $\rightarrow$ más frecuente en Rajoy

Neutro (gris): «España» tiene LR $\approx$ 0.2, es decir, su frecuencia relativa es casi idéntica en ambos oradores.

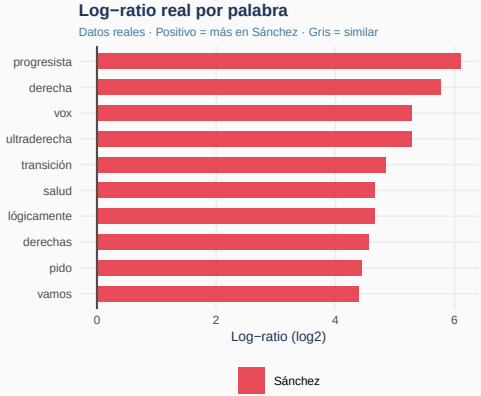

Código R: Log-ratio y tabla combinada

```r
# OPCIÓN A: función manual (didáctica)
calc_LR <- function(O1, O2, N1, N2) {
  log2(((O1+0.5)/N1) / ((O2+0.5)/N2)) |> round(3)
}

# OPCIÓN B (recomendada): quanteda ya devuelve LR en kw$lr
# Los valores provienen del corpus real, no de frecuencias hardcodeadas

# Tabla completa: las frecuencias salen del corpus real
kw |>
  filter(chi2 >= 15.13) |>        # umbral Sketch Engine
  mutate(
    sig = case_when(
      chi2>=15.13~"****", chi2>=10.83~"***",
      chi2>=6.63~"**",    chi2>=3.84~"*",
      TRUE~"n.s.")
  ) |>
  select(feature, chi2, lr, sig) |>
  head(20)
# → "feature" = palabra real más característica de Sánchez
```

Importante: los valores de LL y LR salen **directamente de los textos** a través del pipeline quanteda. No se hardcodea ninguna frecuencia.

Simple Maths: la fórmula de Sketch Engine

Simple Maths (SM)

Imagina que **añades 1.000 ocurrencias ficticias** de cada palabra a ambos corpus antes de comparar. Esto evita que las palabras rarísimas obtengan valores inflados.

$$SM = \frac{(f_{\text{Sánchez}} + 1000)/N_{\text{Sánchez}}}{(f_{\text{Rajoy}} + 1000)/N_{\text{Rajoy}}}$$

Ejemplo con nuestros datos:

«cambio»: Sánchez 48×, Rajoy 15×

$SM = \frac{(48+1000)/29448}{(15+1000)/25653} = 0.90$

$LR = \log_2(1.68) \approx 0.75 \rightarrow$ diferente de SM

El gráfico de la derecha es una idealización para mostrar cómo divergen las dos medidas. Con tus datos reales los valores cambian.

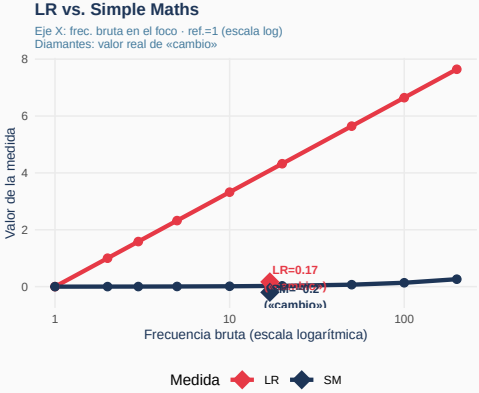

Simple Maths: el problema de las palabras raras

¿Cuándo se infla el log-ratio?

Supón una palabra muy rara, *«biosfera»*, que aparece **1 vez en Sánchez** y **0 veces en Rajoy**. El LR puro es:

$$LR = \log_2 \frac{(1+0.5)/29448}{(0+0.5)/25653} = \log_2(1.74) \approx 0.80$$

Parece moderado. Pero si tuviéramos **0 ocurrencias en ambos** sin el ajuste $+0.5$, obtendríamos $\log_2(0/0) \to$ indefinido.

Simple Maths aplica add-N $= 1000$ en lugar de $+0.5$:

$$SM = \frac{(1+1000)/29448}{(0+1000)/25653} = \frac{0.034}{0.039} = 0.87$$

El resultado es **prácticamente 1** (sin diferencia), porque 1000 domina sobre la frecuencia real de 1. Simple Maths **suprime el efecto** de la palabra rara.

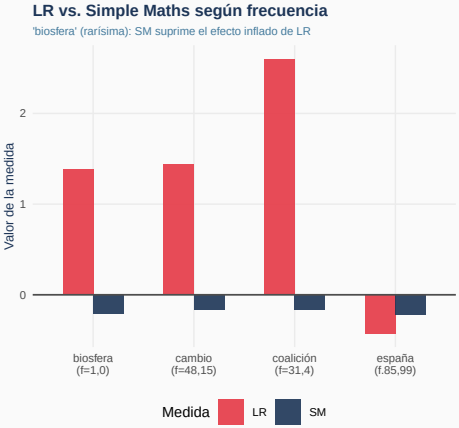

Código R: Simple Maths

```r
calc_SM <- function(O1, O2, N1, N2, add_N=1000) {
  # add_N = 1000: el "suavizado" que aplica Sketch Engine
  ((O1+add_N)/N1) / ((O2+add_N)/N2) |> round(3)
}

# Ejemplo con nuestro corpus (Sánchez foco, Rajoy referencia)
tibble(
  palabra = c("cambio","coalición","déficit","nación"),
  f_san   = c(48, 31,  8, 22),   # frecuencias en Sánchez
  f_raj   = c(15,  4, 29, 18)    # frecuencias en Rajoy
) |>
  mutate(
    LR = mapply(calc_LR, f_san, f_raj, 29448, 25653),
    SM = mapply(calc_SM, f_san, f_raj, 29448, 25653)
  )
# LR y SM divergen mas cuanto mas baja es la frecuencia:
# "deficit" (frec. baja): LR=-1.89  vs  SM=0.98
# "cambio"  (frec. alta): LR= 1.68  vs  SM=0.90
```

Palabras clave: keyness

Keyness

Propiedad de una palabra cuya frecuencia en un **corpus foco** (Sánchez) difiere estadísticamente de un **corpus de referencia** (Rajoy).

En quanteda:

```
kw <- textstat_keyness(dfm_corp,
  target  = docvars(dfm_corp,"orador")
            == "Sanchez",
  measure = "chi2")
```

¿Qué son las palabras del gráfico?

Las **10 palabras con mayor LL** de nuestro corpus real. Son las más «diferenciadoras» entre los dos oradores: aparecen en uno con una frecuencia que sería muy improbable si no hubiera diferencia real.

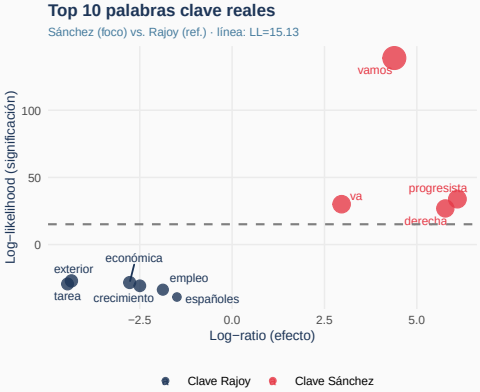

Cómo leer el mapa de palabras clave

¿Qué estoy viendo?

Cada punto es una palabra. Su posición en el gráfico dice dos cosas al mismo tiempo:

Eje vertical (LL): ¿cuán significativa es la diferencia?

- Línea discontinua = LL 15.13 (umbral Sketch Engine)
- **Por encima** → diferencia estadísticamente fiable
- **Por debajo** → puede ser azar

Eje horizontal (log-ratio): ¿en qué corpus es más frecuente y cuánto?

- **Derecha** → más frecuente en Sánchez
- **Izquierda** → más frecuente en Rajoy
- **Tamaño del punto** → mayor log-ratio = diferencia mayor

Lectura de un punto concreto

«ciudadanía» (arriba a la derecha):

LL = 45.2 → diferencia muy significativa

LR = 2.1 → aparece $2^{2.1} \approx$ **4 veces más** en Sánchez

«autonomía» (abajo a la derecha):

LL = 9.3 → **por debajo de la línea**: no supera el umbral de Sketch Engine, no se considera palabra clave fiable.

Regla práctica

Solo son verdaderamente palabras clave los puntos que están **por encima de la línea discontinua**.

Código R: keyness con quanteda

```r
library(quanteda); library(quanteda.textstats)

# 1. Leer y crear corpus
textos <- map_chr(
  c("2011_Rajoy.txt","2016_Rajoy.txt",
    "2020_Sanchez.txt","2023_Sanchez.txt"),
  ~ paste(readLines(.x, encoding="UTF-8"), collapse=" ")
)
corp <- corpus(textos)
docvars(corp,"orador") <- c("Rajoy","Rajoy","Sanchez","Sanchez")

# 2. Tokenizar y construir DFM
toks <- tokens(corp, remove_punct=TRUE) |>
  tokens_tolower() |> tokens_remove(stopwords("es"))
dfm_corp <- dfm(toks)

# 3. Calcular keyness (Sánchez foco vs. Rajoy referencia)
kw <- textstat_keyness(dfm_corp,
        target  = docvars(dfm_corp,"orador")=="Sanchez",
        measure = "lr")
head(kw, 20)
```

Dispersión: no todas las palabras son iguales

Dispersión

Cómo se **distribuye** una palabra a lo largo de los textos. Una palabra frecuente pero concentrada en un texto no es representativa del corpus.

Medidas:

- % de textos en que aparece *(SE: mín. 50 %)*
- **Deviation of Proportions** (DP):
  0 = perfecta dispersión · 1 = concentrada en uno

Ejemplo con nuestro corpus:

«ciudadanía» → aparece en los 4 discursos = bien dispersa

noviembre → solo en Sánchez 2020 = concentrada

No sería válida como palabra clave aunque tuviera LL alto.

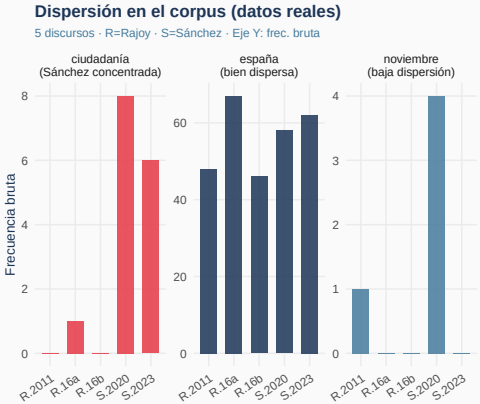

Cómo leer el gráfico de dispersión

¿Qué muestra el gráfico anterior?

Cada panel es una palabra. Las barras muestran cuántas veces aparece en **cada uno de los 5 discursos**.

«españa» (azul): presente en todos los discursos → **perfectamente dispersa**, útil como referencia.

«ciudadanía» (rojo): aparece casi exclusivamente en Sánchez → **concentrada en un sub-corpus**. Indica un uso ideológicamente diferenciado.

Tercera palabra (azul claro): aparece en 1 o 2 discursos → **baja dispersión**. Sketch Engine la **excluiría** de las palabras clave.

¿Por qué importa la dispersión?

Si una palabra aparece muchas veces pero concentrada en un único texto, puede ser un tema puntual, no un rasgo del estilo del orador.

La dispersión garantiza **representatividad** en todo el corpus.

Umbral en Sketch Engine

Una palabra debe aparecer en al menos el **50 % de los textos** del corpus foco para ser candidata a palabra clave.

Parte III: Colocaciones

Colocaciones y medidas de asociación

Colocación
Par de palabras que co-ocurren **más de lo esperable por azar** en una ventana de $\pm k$ palabras alrededor de un nodo.

Mutual Information (MI):
$MI = \log_2 \frac{P(w_1, w_2)}{P(w_1) \cdot P(w_2)}$
Favorece colocaciones **raras pero fijas** (fraseología).

t-score:
$t = (O - E)/\sqrt{O}$
Favorece colocaciones **frecuentes** (patrones gramaticales).

logDice: equilibrio entre ambas, más robusto con frecuencias bajas.

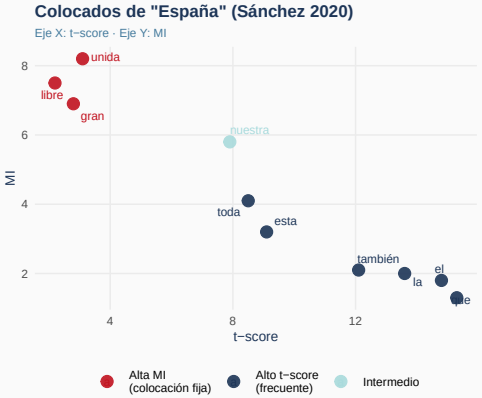

Código R: calcular colocaciones

```r
library(quanteda); library(quanteda.textstats)

# Colocaciones del nodo "españa" (ventana +-3)
col_espana <- tokens_select(toks, "españa",
                selection="keep", window=3, padding=TRUE) |>
  textstat_collocations(size=2, min_count=3)

# Ver las 15 principales por lambda (aprox. MI)
col_espana |> arrange(desc(lambda)) |> head(15)

# Para MI, t-score y logDice simultaneamente:
# install.packages("collostructions")
library(collostructions)
# collex() calcula todas las medidas a la vez
```

Concordancias: «españa» en contexto

Concordancias de «españa» (muestra aleatoria de 20)

Contexto ±5 palabras · [nodo] entre corchetes · Sin puntuación

```
inferior a la media europea y recuerden que mientras en [españa] se produ
y ocho meses con un gobierno en funciones la frase [españa] necesita un g
tan evidente como lo acredita el hecho de que en [españa] desde el año si
mismo ni de la fortaleza ni de la estabilidad que [españa] necesita tendr
un partido que tiene años de vida nació cuando en [españa] solo tenía der
la consolidación del crecimiento a la creación de empleo digno [españa] s
las identidades nacionales dentro de nuestro marco constitucional ha perf
mercado de trabajo hay zonas geográficas enteras también aquí en [españa]
y vamos a desplegar una estrategia nacional de alimentación para [españa]
en nombre de españa y en nombre del interés de [españa] en defensa de la
```

Orador

a Rajoy

a Sánchez

Las concordancias revelan los **patrones fraseológicos** que rodean a una palabra clave. Rajoy tiende a usar *españa* en contextos de unidad y nación; Sánchez en contextos de progreso y diálogo.

Top 5 colocados de «españa»: Rajoy y Sánchez

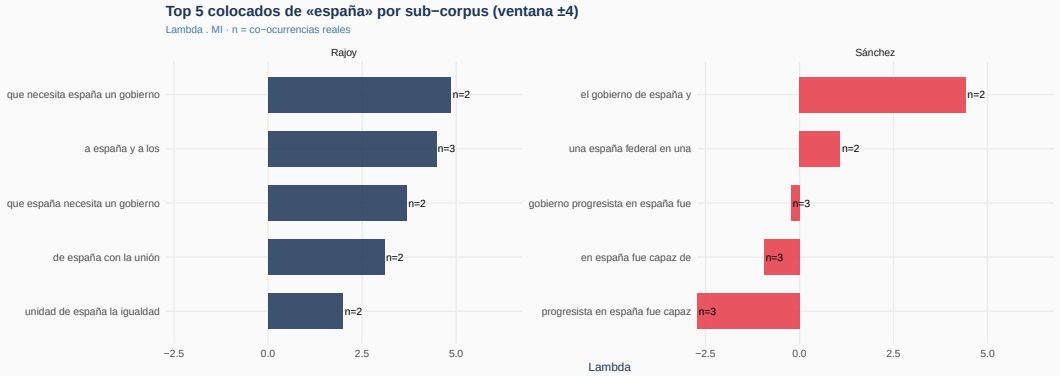

Bigramas y trigramas más frecuentes

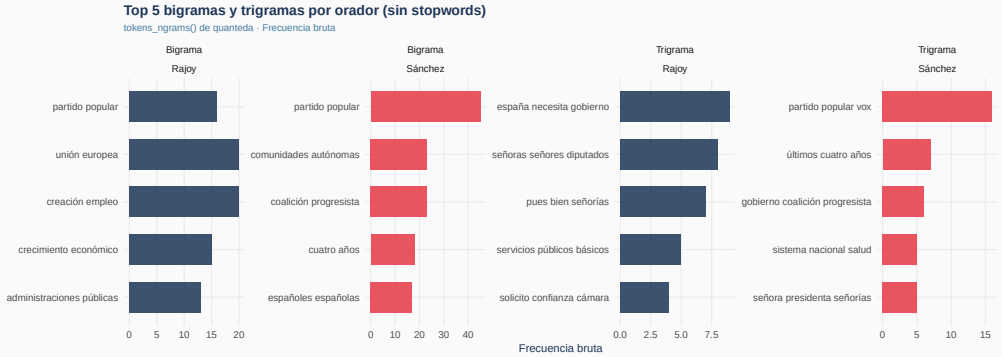

En R: `tokens_ngrams(toks, n=2)` para bigramas · `n=3` trigramas · después `dfm() |> dfm_group() |> topfeatures()`

De Sketch Engine a R: el mismo cálculo

¿Qué hace Sketch Engine internamente?

1. Tokeniza y normaliza el texto
2. Cuenta frecuencias brutas
3. Normaliza por longitud del corpus
4. Calcula LL para cada tipo léxico
5. Calcula Simple Maths como efecto
6. Filtra por LL $\geq$ 15.13 y dispersión

Podemos **replicar cada paso en R** con control total.

Ventaja: sabemos exactamente qué cálculo se hace y podemos ajustarlo a nuestra investigación.

Pipeline en R

`readLines()` $\rightarrow$ lectura

`tokens()` $\rightarrow$ tokenización

`dfm()` $\rightarrow$ matriz de frecuencias

`textstat_keyness()` $\rightarrow$ LL + LR

`ggplot()` $\rightarrow$ visualización

Reproducibilidad

Cada paso es auditable y replicable por cualquier otro investigador con el mismo script.

Código R: leer corpus y construir DFM

```r
library(tidyverse); library(quanteda)

# Leer los cinco discursos
archivos <- c("2011_Rajoy.txt","2016_Rajoy.txt","2016b_Rajoy.txt",
              "2020_Sanchez.txt","2023_Sanchez.txt")
textos   <- map_chr(archivos,
             ~paste(readLines(.x, encoding="UTF-8"), collapse=" "))

# Corpus con metadatos
corp <- corpus(textos)
docvars(corp,"orador") <- c("Rajoy","Rajoy","Rajoy","Sanchez","Sanchez")
docvars(corp,"anio")   <- c(2011, 2016, 2016, 2020, 2023)

# Tokenizar y construir DFM
toks <- tokens(corp, remove_punct=TRUE, remove_numbers=TRUE) |>
  tokens_tolower() |> tokens_remove(stopwords("es"))
dfm_corp <- dfm(toks)

dim(dfm_corp)           # 5 documentos x ~8.000 tipos lexicos
topfeatures(dfm_corp)   # palabras mas frecuentes
```

Código R: gráfico LL × log-ratio

```r
library(quanteda.textstats); library(ggrepel)

kw <- textstat_keyness(dfm_corp,
        target  = docvars(dfm_corp,"orador")=="Sanchez",
        measure = "lr") |>
  mutate(grupo = case_when(
    lr > 0 & chi2 >= 15.13 ~ "Clave Sanchez",
    lr < 0 & chi2 >= 15.13 ~ "Clave Rajoy",
    TRUE ~ "No significativa"))

ggplot(kw[1:40,], aes(x=lr, y=chi2, color=grupo, label=feature)) +
  geom_point(aes(size=abs(lr)), alpha=0.8) +
  geom_text_repel(size=2.8) +
  geom_hline(yintercept=15.13, linetype="dotted") +
  geom_vline(xintercept=0,     linetype="dashed") +
  scale_color_manual(values=c("Clave Sanchez"="#E63946",
    "Clave Rajoy"="#1D3557","No significativa"="#A8DADC")) +
  labs(x="Log-ratio", y="Log-likelihood", color=NULL) +
  theme_minimal()
```

Replicar la plantilla Excel de Birmingham

```r
# La plantilla de Fuoli (Univ. Birmingham) hace exactamente esto:
freq_tabla <- read_csv("mi_tabla_frecuencias.csv")
# Columnas: word, freq_A, freq_B, total_A, total_B

resultado <- freq_tabla |>
  mutate(
    E_A = (freq_A+freq_B)*total_A/(total_A+total_B),
    E_B = (freq_A+freq_B)*total_B/(total_A+total_B),
    LL  = 2*(ifelse(freq_A>0, freq_A*log(freq_A/E_A), 0)+
             ifelse(freq_B>0, freq_B*log(freq_B/E_B), 0)),
    LR  = log2((freq_A+0.5)/total_A/((freq_B+0.5)/total_B)),
    SM  = ((freq_A+1000)/total_A)/((freq_B+1000)/total_B),
    sig = case_when(LL>=15.13~"****",LL>=10.83~"***",
                    LL>=6.63~"**",   LL>=3.84~"*",
                    TRUE~"n.s.")
  ) |>
  filter(LL >= 15.13) |> arrange(desc(abs(LR)))
```

Archivo Excel en https://github.com/acabedo/navarra2026

Parte V: Aplicación integrada

Caso completo: mapa léxico de los discursos

Interpretación: cuatro cuadrantes

Eje Y — Log-likelihood

Mide la **significación estadística**

- **Por encima** de la línea (LL=15.13): diferencia fiable, no achacable al azar
- Más arriba = más significativo

Eje X — Log-ratio

Mide el **tamaño del efecto**

- Positivo → más frecuente en **Sánchez**
- Negativo → más frecuente en **Rajoy**
- Cerca de 0 → **frecuencia similar** en ambos (*«Neutro»*): *España* aparece en ambos con parecida frecuencia relativa, por eso su punto es gris y está cerca del centro vertical

Los cuatro cuadrantes

↑ **derecha**: Palabras clave de Sánchez (significativas y más frecuentes en él)

↑ **izquierda**: Palabras clave de Rajoy

↓: Por debajo de la línea → no significativas (pueden ser azar)

Conclusión lingüística (datos reales)

Léxico de **Sánchez**: progresista, derecha, ultraderecha.

Léxico de **Rajoy**: esfuerzos, demás, cambiado.

Estas son las palabras reales con mayor log-ratio y LL en el corpus.

Evolución diacrónica del léxico

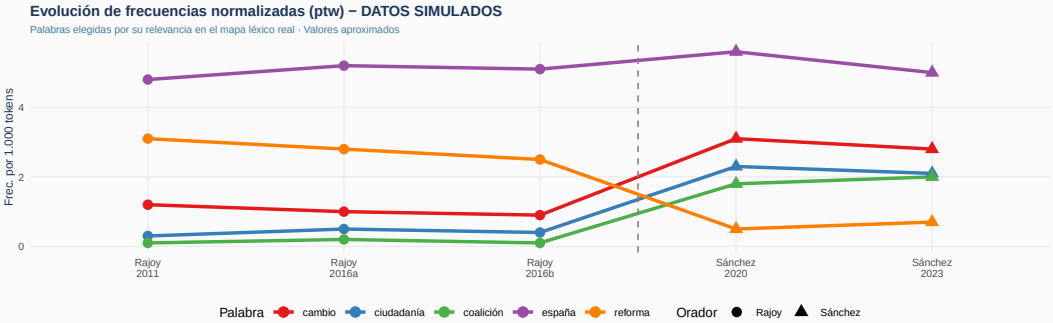

Ejemplos reales: top palabras por cada medida del Excel

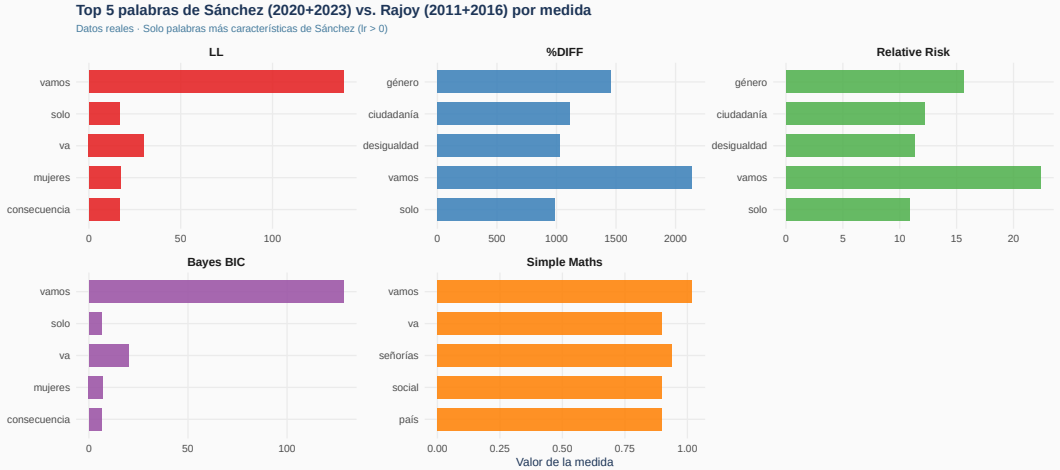

Otras medidas del Excel (I): %DIFF y Relative Risk

%DIFF
Diferencia porcentual de frecuencias normalizadas.

$$\%DIFF = \frac{(f_1/N_1) - (f_2/N_2)}{f_2/N_2} \times 100$$

Intuitiva pero **muy sensible** a frecuencias bajas.

Relative Risk (RR)
Cuántas veces más probable es la palabra en el foco:

$$RR = \frac{f_1/N_1}{f_2/N_2}$$

Similar al log-ratio pero en escala lineal. $RR = 2 =$ el doble.

Relación con log-ratio
$RR = 2^{LR}$

Un $LR = 1$ equivale a $RR = 2$ (el doble de frecuente).

Un $LR = 2$ equivale a $RR = 4$ (cuatro veces más).

La escala logarítmica del LR es más simétrica y estable para comparar.

%DIFF vs. RR
%DIFF puede ser negativo o positivo: intuitivo para audiencias no expertas.

RR es siempre positivo: más fácil de comparar entre palabras.

Otras medidas del Excel (II): OR, BIC y ELL

Odds Ratio (OR)

Razón de probabilidades; más usado en medicina:

$$OR = \frac{f_1/(N_1 - f_1)}{f_2/(N_2 - f_2)}$$

En corpus grandes con palabras raras, OR $\approx$ RR.

Bayes Factor BIC

Alternativa bayesiana al p-valor. Cuantifica la **evidencia** a favor de H_1. BIC > 10: evidencia fuerte. No requiere asumir distribución normal.

ELL (Effect size for Log-Likelihood)

Versión estandarizada del LL: permite comparar entre estudios con corpus de distinto tamaño.

¿Cuándo usar OR o BIC?

OR: cuando el diseño del estudio es de tipo caso-control o cuando se quiere comparar con estudios médicos o de ciencias sociales.

BIC: cuando se quiere dar evidencia sin asumir distribución χ^2, o cuando el corpus es pequeño y el p-valor puede ser inestable.

Resumen y cierre

Lo que hemos visto hoy

Estadística básica

- Población / muestra / variable / riqueza léxica
- H_0 e H_1 · Errores tipo I y II
- Valor p · Tamaño del efecto
- Significación $\neq$ relevancia lingüística

Estadística de corpus

- Frecuencia normalizada (ptw/pmw)
- Log-likelihood $\rightarrow$ significación
- Log-ratio $\rightarrow$ efecto · Simple Maths $\rightarrow$ efecto suavizado
- %DIFF · RR · OR · BIC · ELL
- Keyness = sig. + efecto + dispersión
- Colocaciones: MI, t-score, logDice
- N-gramas: bigramas y trigramas

R en la práctica

- `corpus()` · `tokens()` · `dfm()`
- `textstat_keyness()` · `textstat_collocations()`
- `tokens_ngrams()` · `kwic()`
- `ggplot2` + `ggrepel`

Significación estadística

$$\neq$$

Relevancia lingüística

Materiales
https://github.com/acabedo/navarra2026

¿Qué medida usar? Guía práctica

Medida	Cuándo usarla	Limitación principal
LL	Siempre (significación)	Crece con el tamaño del corpus
Log-ratio	Efecto principal; corpus grandes	Inestable con frec. muy bajas
Simple Maths	Corpus pequeños o frec. bajas	Menos interpretable que LR
%DIFF	Comunicar a audiencias no expertas	Muy sensible a frec. bajas
Relative Risk	Comparar magnitud (escala lineal)	Equivale a 2^{LR}
Odds Ratio	Estudios con diseño caso-control	Sobreestima con frec. altas
BIC	Evidencia bayesiana	Requiere interpretación distinta
ELL	Comparar entre estudios	Menos conocido en lingüística

Recomendación estándar en lingüística de corpus

Reporta siempre **LL** (significación) + **log-ratio** (efecto) + **dispersión** (% textos). Es lo que hacen Fuoli & Beelitz (2024) y el estándar de Sketch Engine.

Tabla resumen de medidas

Medida	Qué mide	Rango	SE	Excel
Frec. norm.	Frecuencia relativa	≥ 0	Sí	Sí
Log-likelihood	Significación	≥ 0	Sí (15.13)	Sí
Log-ratio	Tamaño del efecto	$\mathbb{R}$	Sí	Sí
Simple Maths	Efecto suavizado	> 0	Sí	No
%DIFF	Dif. porcentual	$\mathbb{R}$	No	Sí
Relative Risk	Ratio lineal de frec.	> 0	No	Sí
Odds Ratio	Razón de probabilidades	> 0	No	Sí
Bayes BIC	Evidencia bayesiana	$\mathbb{R}$	No	Sí
ELL	Efecto estandarizado	$[0, 1]$	No	Sí
MI	Asoc. colocados	$\mathbb{R}$	Sí	No
t-score	Asoc. frec.	$\mathbb{R}$	Sí	No
logDice	Asoc. robusta	$(0, 14]$	Sí	No

Regla de oro
Usa **LL** para decidir si una diferencia es significativa y **log-ratio** para saber cuánto importa. Reporta siempre ambos junto con la dispersión.

Referencias y recursos

Lecturas

Fuoli, M. & Beelitz, A. (2024). Framing the path to net zero. *IJCL*, 29(3), 361–388.

Hardie, A. (2014). Log ratio: An informal introduction. CASS, Lancaster University.

Rayson, P. & Garside, R. (2000). Comparing corpora using frequency profiling. *ACL Workshop*.

Baker, P. (2006). *Using Corpora in Discourse Analysis*. Continuum.

Herramientas

R: https://www.r-project.org · RStudio: https://posit.co/download/rstudio-desktop

Sketch Engine: https://www.sketchengine.eu · AntConc:
https://www.laurenceanthony.net/software/antconc

Materiales del seminario

https://github.com/acabedo/navarra2026 — código R · corpus .txt · plantilla Excel · diapositivas

¿Preguntas?

Adrián Cabedo Nebot

Universitat de València · Catedrático de Lengua Española

adrian.cabedo@uv.es

https://github.com/acabedo/navarra2026

Materiales bajo licencia CC BY 4.0